

Modelo de Fidelización y Recompra

Online Retail II · UK · 2009–2011

Modelo de probabilidad de recompra para acciones de fidelización y retención comercial

LightGBM + Optuna

SHAP Explainability

RFM Engineering

3 Segmentos Accionables

Objetivos y Estructura

Objetivo de Negocio

Retailer online UK con artículos de regalo al por mayor y detalle (2009–2011).

Construir un modelo supervisado que estime la probabilidad de que un cliente vuelva a comprar.

Segmentar la base en 3 grupos con acciones diferenciadas:

- FIDELIZACIÓN (prob > 0.66)
- POTENCIAL (0.33–0.66)
- RETENCIÓN (prob < 0.33)



1.067.371 filas · 5.861 clientes únicos · 43 países · 5.305 productos

Pipeline del Proyecto (12 etapas)

1 Setup & Librerías

2 Carga de Datos

3 Calidad de Datos

4 EDA Profundo

5 Feature Engineering (17 vars)

6 Dataset de Modelado

7 Benchmark 7 Algoritmos

8 Optimización Optuna (60 trials)

9 Evaluación Completa (AUC, PR, Lift)

10 Explicabilidad SHAP

11 Segmentación Accionable


12 Resumen Ejecutivo

Calidad de Datos & Limpieza

Valores Nulos por Columna




Distribución de Price y Quantity



Criterio de exclusión		Razón	Impacto
Invoice empieza en 'C'		Devoluciones — no son compras reales	~16% filas
Customer ID nulo		Sin ID no podemos construir perfil cliente	~22% filas
Price ≤ 0 / Quantity ≤ 0		Precios erróneos o ajustes de inventario	<1%
Duplicados exactos		Registros duplicados en sistema fuente	~1.1%

EDA — Evolución Temporal

Revenue, Facturas, Clientes Activos y Ticket Medio — mensual





Patrones por día de semana, hora del día y trimestre



EDA — Geografía, Productos & Concentración


Análisis geográfico — Revenue, Revenue/cliente y Clientes únicos (excl. UK)



🇬🇧 UK = 83.8% del revenue total

🌐 EIRE 2º mercado con 3.4% del revenue


Curva de Pareto — 21.6% de productos genera el 80% del revenue · 23% de clientes genera el 80% del revenue



EDA — Análisis RFM & Cohortes de Retención


Distribución RFM — Recency, Frequency, Monetary, AvgTicket

Análisis RFM descriptivo — todos los clientes



Mapa de calor — % Retención mensual por cohorte

Análisis de Cohortes — % Retención mensual por cohorte de adquisición



21.0%

Retención mes 1

~17–20%

Retención meses 2–8

18.2%

Retención mes 12 (recuperación)

199 días

Recency media del cliente

Feature Engineering — 17 Variables Predictoras

Estrategia temporal: Ventana de observación (hasta cutoff 2010-12-09) → Features | Ventana de predicción (posterior) → Target

RFM Clásico

- recency_days
- frequency
- total_revenue

Estadísticas de Ticket

- avg_ticket
- std_ticket
- max_ticket
- min_ticket


Variable Objetivo

62.9%

Clientes que recompraron (1)
4.294 clientes · 2.699 positivos

Distribución de features por clase (Recompra vs No Recompra)


Distribución de features por clase de recompra (normalizada)



Benchmark de 7 Algoritmos & Optimización con Optuna

AUC-ROC CV 5-fold — Algoritmos sin optimizar




Benchmark — AUC-ROC CV 5-fold (modelos base sin optimizar)



Algoritmo	AUC (mean)	AUC (std)
Logistic Regression	0.7677	±0.0122
AdaBoost	0.7723	±0.0142
Gradient Boosting	0.7804	±0.0152
XGBoost	0.7534	±0.0148
LightGBM	0.7639	±0.0168
Random Forest	0.7644	±0.0182
Extra Trees	0.7644	±0.0225

🏆 GBM lideró el benchmark base (AUC 0.7804)

Convergencia Optuna (60 trials · TPE Sampler) — XGBoost, LightGBM, Random Forest



Evaluación del Modelo Final — LightGBM Optimizado

0.8124

AUC-ROC

↑ vs random 0.5

0.8832

Average Precision

Precisión media PR

0.1702

Brier Score

↓ baseline 0.233

0.8021

F1-Score







umbral=0.5

1.56x

Lift Top 10%
vs selección aleatoria

Curva ROC · PR · Gain Chart · Distribución de Prob. · Calibración · F1 vs Umbral

Evaluación completa — LightGBM optimizado con Optuna



Matriz de Confusión

Matriz de confusión (umbral=0.5)
Precisión: 73.7%


True label	Predicted label	
	No recompra	Recompra
No recompra	175	144
Recompra	82	458

Explicabilidad SHAP


Top 5 variables por |SHAP| medio

1	total_revenue	0.317
Revenue total del cliente — principal driver de lealtad		
2	recency_days	0.288
Días desde última compra — frescura de la relación		
3	frequency	0.228
Número de facturas — hábito de compra consolidado		
4	total_items	0.174
Unidades compradas acumuladas		
5	std_ticket	0.121
Variabilidad del ticket — irregularidad como señal de riesgo		


Beeswarm — impacto y dirección de cada feature



Importancia global |SHAP|





Dependence plots — top 4 features



Segmentación Accionable — 3 Grupos CRM

Distribución de segmentos y probabilidades de recompra — 4.294 clientes



FIDELIZACIÓN

prob > 0.66

2.013 clientes (46.9%)

- Programa loyalty premium con recompensas acumulativas
- Early access a nuevas colecciones y productos
- Newsletter personalizada de alto valor
- Upselling y cross-selling de gama alta



POTENCIAL

0.33 – 0.66

1.731 clientes (40.3%)

- Emails de re-engagement con incentivo moderado
- Descuentos por volumen en segunda compra
- Recordatorio de items en wishlist
- Encuesta de satisfacción + cupón



RETENCIÓN

prob < 0.33

550 clientes (12.8%)

- Descuento de recuperación urgente (-20%)
- Win-back email con oferta exclusiva limitada
- Investigar motivo de abandono (encuesta corta)
- Evaluar coste-beneficio de recuperación

Conclusiones & Próximos Pasos

✓ Conclusiones Principales

LightGBM ganador

AUC-ROC 0.8124 en test — excelente discriminación para un dataset retail real. +2.2pp vs modelo base.

Lift de 1.56×

Contactando solo el 10% top, capturamos el 15.6% adicional de compradores respecto al aleatorio.

RFM sigue mandando

Revenue total, recency y frequency explican el 83% del impacto SHAP. La lógica RFM clásica se confirma.

Segmentación rentable

46.9% Fidelización · 40.3% Potencial · 12.8% Retención — base para acciones CRM diferenciadas.

Alta tasa de recompra

62.9% de clientes recompró en los 12 meses siguientes — mercado con fuerte potencial de loyalty.

🚀 Próximos Pasos

Producción & API

Desplegar el modelo como microservicio REST para scoring en tiempo real en el CRM.

Calibración fina

Aplicar CalibratedClassifierCV isotónico para mejorar las probabilidades absolutas.

Modelo de CLV

Combinar prob. de recompra × ticket medio para estimar el CLV a 12 meses.

Análisis de sensibilidad

Testear el umbral de corte en A/B test real con grupo de control en cada segmento.

Datos enriquecidos

Incorporar datos de email marketing, devoluciones y NPS para mejorar el AUC.